탐색적 데이터 분석(EDA) 보고서

Blood Transfusion Service Center 데이터셋

헌혈 서비스 센터 고객 행동 분석

과 목 명 : 데이터관리론
제 출 일 : 2026.03.23
학 과 : 빅데이터과
학 번 : 2555031
이 름 : 이 지 원

목차

1. 서론 (Introduction)

1.1 분석 배경 및 목적 3
1.2 데이터셋 설명 4
1.3 주요 분석 질문 (Key Questions) 4

2. 데이터 프로파일링 및 기초 탐색 (Data Profiling)

2.1 데이터 불러오기 (4가지 방법) 5
2.2 데이터 명세 확인 5
2.3 결측치(Missing Value) 분석 5
2.4 기초 통계량 분석 6
2.5 데이터 정제(Cleaning) 결과 6

3. 변수별 개별 특성 분석 (Univariate Analysis)

3.1 수치형 변수 분석 7
3.2 와곡 변수 전처리 8
3.3 범주형 변수 분석 9
3.4 파생 변수 생성 (Binning) 10

4. 상관관계 및 관계 분석 (Multivariate Analysis)

4.1 수치형 변수 간 상관관계 11
4.2 타겟 변수(Class) 기반 심층 분석 13
4.3 세그먼트별 비교 분석 14

5. 핵심 인사이트 및 가설 검정 (Key Insights)

5.1 주요 패턴 발견 15
5.2 가설 검증 결과 15
5.3 예상치 못한 발견 (Unexpected Findings) 18

6. 결론 및 향후 방향 (Conclusion & Recommendation)

6.1 분석 요약 20
6.2 비즈니스 제언 (Action Plan) 20
6.3 한계점 및 추후 과제 21

부록 — 코랩 실습 코드 (GitHub) 22

1. 서론 (Introduction)

1.1 분석 배경 및 목적

본 보고서는 물류 공학 및 경영학적 관점에서 혈액 공급망(Blood Supply Chain)의 운영 효율을 탐색하기 위해 대만 신주시 헌혈 서비스 센터(Blood Transfusion Service Center) 데이터를 분석 대상으로 선정하였다.

혈액은 인공적으로 제조할 수 없는 부패성 자산(Perishable Assets)으로, 적혈구(42일)·혈소판(5일)이라는 극도로 짧은 유효기간을 가진다. 재고로 축적할 수 없다는 특성상, 수요가 발생하는 시점에 정확히 공급을 맞추는 JIT(Just-In-Time) 시스템의 성공 여부가 곧 인명과 직결되는 극한의 공급망 과제이다.

본 데이터셋은 헌혈 버스가 3개월 주기로 대학을 방문하여 수집한 기록으로, 단순한 의료 데이터를 넘어 이동형 물류 거점(Mobile Hub)의 운영 효율을 분석하기에 최적화된 물류 공학적 시나리오를 제공한다. 이를 통해 혈액 공급망의 구조적 문제를 데이터 기반으로 진단하고, 운영 효율 개선을 위한 인사이트를 도출하는 것을 본 보고서의 핵심 목적으로 삼는다.

비즈니스 문제 정의 (Business Problem)

본 분석이 해결하고자 하는 핵심 비즈니스 문제는 다음 3가지이다.

문제 ① 수요-공급 역전(Crossover Point)

대만은 초고령 사회 진입을 앞두고 있으며, 2027년경 혈액 수요가 공급을 추월하는 임계점에 도달할 것으로 예측된다. 이 시점을 대비한 정밀한 공급망 설계가 시급한 과제이다.

문제 ② 폐기(Wastage)와 부족(Shortage)의 이중고

혈액 부족은 수술 취소·사망률 증가로 직결되지만, 과도한 채혈은 유효기간 내 사용되지 못하고 폐기되는 경제적·윤리적 손실을 야기한다. 전 세계 혈액 폐기율은 약 0~6.7% 수준으로 보고된다.

문제 ③ 헌혈자 유지(Retention)의 경제적 효율성

신규 헌혈자 모집 비용은 기존 헌혈자 유지 비용보다 훨씬 높다. RFMTC 모델을 통해 이탈 위험군(Churn Risk)을 조기에 식별하고 관리하는 것이 혈액원 운영의 재무적 건전성을 확보하는 핵심 과제이다.

1.2 데이터셋 설명

항목	내용
데이터셋명	Blood Transfusion Service Center
출처	OpenML (https://www.openml.org), ID: 1464 / UCI ML Repository
수집 방법	대만 신주시 헌혈 버스가 3개월 주기로 대학 방문하여 수집
레코드 수	748행 × 5열
원본 논문	Yeh et al. (2008), Knowledge discovery on RFM model using Bernoulli sequence
타겟 변수	Class (1 = 2007년 3월 헌혈, 0 = 미헌혈)

변수(컬럼) 설명

본 데이터셋은 RFMTC 모델(**Recency, Frequency, Monetary, Time, Class**)을 기반으로 구성되어 있다.

변수명	RFMTC	의미	단위	타입
Recency	R	마지막 헌혈 이후 경과 시간	월(month)	수치형
Frequency	F	총 헌혈 횟수	회	수치형
Monetary	M	총 헌혈량	c.c.	수치형
Time	T	첫 헌혈 이후 경과 시간	월(month)	수치형
Class	C	헌혈 여부 (타겟)	1=헌혈, 0=미헌혈	범주형

1.3 주요 분석 질문 (Key Questions)

본 분석에서는 물류 공학·구독 경제·생물 통계학적 개념을 결합한 4가지 가설을 설정하였다. 각 가설은 데이터 선정 이유 및 비즈니스 문제와 직접적으로 연결된다.

가설 1 — 공급 주기 집중 현상 (비즈니스 문제 ①: 수요-공급 역전 연결)

"헌혈 버스의 3개월 주기 방문 특성으로 인해 Time(첫 헌혈 이후 경과 월) 변수의 분포가 특정 구간에 집중되어 있으며, 이는 이동형 물류 거점(Mobile Hub) 운영의 구조적 공급 불균형을 나타내는 증거일 것이다."

→ 검증 방법: Time 변수 히스토그램에서 3의 배수 구간(3, 6, 9개월...)에 데이터 집중 여부 확인

가설 2 — 헌혈자 이탈 패턴, Churn Rate (비즈니스 문제 ③: 헌혈자 유지 비용 연결)

"마지막 헌혈로부터 3~6개월 이내인 헌혈자는 재헌혈 확률이 높은 활성 구독자(Active Subscriber) 상태이며, 이 기간을 초과할수록 재헌혈 확률이 급격히 낮아지는 로그함수적 이탈 패턴이 존재할 것이다."

→ 검증 방법: Recency 구간별(0~3개월, 3~6개월, 6개월 이상) Class=1 비율 비교

가설 3 — 고빈도 헌혈자의 JIT 병목 (데이터 선정 이유: JIT 시스템 연결)

"헌혈 횟수(Frequency)가 일정 수준 이상인 고빈도 헌혈자는 신체 회복 기간으로 인해 Recency(마지막 헌혈 경과 시간)가 오히려 길어지는 비선형 관계가 존재할 것이다. 이는 JIT 공급망에서 핵심 공급자를 과도하게 활용할 때 발생하는 병목(Bottleneck) 현상과 동일한 구조이다."

→ 검증 방법: Frequency와 Recency의 산점도(Scatter Plot) 및 상관계수 분석

가설 4 — 고헌혈자의 공급 부족 역설 (비즈니스 문제 ②: 폐기 vs 부족 연결)

"총 헌혈량(Monetary)이 높은 고헌혈자일수록 재헌혈(Class=1) 확률이 오히려 낮아지는 역설적 패턴이 존재할 것이다. 이는 혈액 공급망에서 폐기 위험보다 핵심 공급자 이탈로 인한 공급 부족이 더 큰 위험임을 시사한다."

→ 검증 방법: Monetary 구간별 Class=1 비율 비교 및 상관계수 분석

2. 데이터 프로파일링 및 기초 탐색 (Data Profiling)

2.1 데이터 불러오기 (4 가지 방법)

아래 4가지 방법으로 동일한 데이터를 불러왔으며, 결과가 동일함을 확인하였다.

① openml 라이브러리 사용

openml.datasets.get_dataset(1464)로 데이터 취득. Shape: (748, 5)

② fetch_openml 사용 (sklearn)

sklearn.datasets.fetch_openml으로 데이터 취득. Shape: (748, 5)

③ StringIO 사용

URL에서 CSV 텍스트를 받아온 뒤 메모리에서 바로 읽기. Shape: (748, 5)

④ requests 사용

URL에서 CSV 다운로드 → 파일로 저장 → 읽기. Shape: (748, 5)

→ 4가지 방법 모두 (748, 5) 동일한 결과 확인 완료. 이후 분석은 Class 변수를 0/1로 변환한 통합 데이터프레임(df)을 사용하였다.

※ 4가지 방법의 실행 코드 및 출력 결과는 코랩 실습 파일(GitHub) 참조

2.2 데이터 명세 확인

항목	값
전체 레코드 수	748행
컬럼 수	5열
수치형 변수	5개 (Recency, Frequency, Monetary, Time, Class)
범주형 변수	1개 (Class — 실질적 범주형)
중복 행 수	215개

2.3 결측치(Missing Value) 분석

변수명	결측치 수	결측 비율(%)	처리 전략
Recency	0	0.0%	처리 불필요
Frequency	0	0.0%	처리 불필요
Monetary	0	0.0%	처리 불필요
Time	0	0.0%	처리 불필요
Class	0	0.0%	처리 불필요

→ 총 결측치: 0개. 결측치가 없으므로 별도 처리가 불필요하다.

2.4 기초 통계량 분석

통계량	Recency	Frequency	Monetary	Time
평균 (mean)	9.51	5.51	1378.68	34.28
중앙값 (median)	7.00	4.00	1000.00	28.00
최빈값 (mode)	2.00	1.00	250.00	4.00
표준편차 (std)	8.10	5.84	1459.83	24.38
최솟값 (min)	0.00	1.00	250.00	2.00
최댓값 (max)	74.00	50.00	12500.00	98.00
Q1 (25%)	2.75	2.00	500.00	16.00
Q2 (50%)	7.00	4.00	1000.00	28.00
Q3 (75%)	14.00	7.00	1750.00	50.00
90% 백분위수	21.00	12.00	3000.00	73.00
범위 (range)	74.00	49.00	12250.00	96.00
사분위범위 (IQR)	11.25	5.00	1250.00	34.00

4개 수치형 변수 모두 **평균이 중앙값보다 크게 나타나 오른쪽 꼬리(양의 왜도)를 가진 분포**임을 알 수 있다. 특히 Frequency와 Monetary는 평균과 중앙값의 차이가 27.5%로, 큰 값 쪽 이상치의 존재를 시사한다. Recency 역시 평균(9.51) vs 중앙값(7.00)으로 26.4% 차이가 발생하였다.

2.5 데이터 정제(Cleaning) 결과

중복 행 확인

총 215개 중복 행 확인. 동일한 값이 서로 다른 헌혈자의 기록일 수 있으므로 유지하였다.

이상치 탐지 (IQR 방법: Q1 - 1.5×IQR 미만, Q3 + 1.5×IQR 초과)

변수	Q1 / Q3 / IQR	하한 / 상한	이상치 수	비율
Recency	2.75 / 14.0 / 11.25	-14.13 / 30.88	7개	0.9%
Frequency	2.0 / 7.0 / 5.0	-5.5 / 14.5	45개	6.0%
Monetary	500 / 1750 / 1250	-1375 / 3625	45개	6.0%
Time	16.0 / 50.0 / 34.0	-35.0 / 101.0	0개	0.0%

→ 처리 방침:**이상치는 실제 헌혈패턴을 반영하는 의미있는 값이므로 제거하지 않고 유지**하였다.

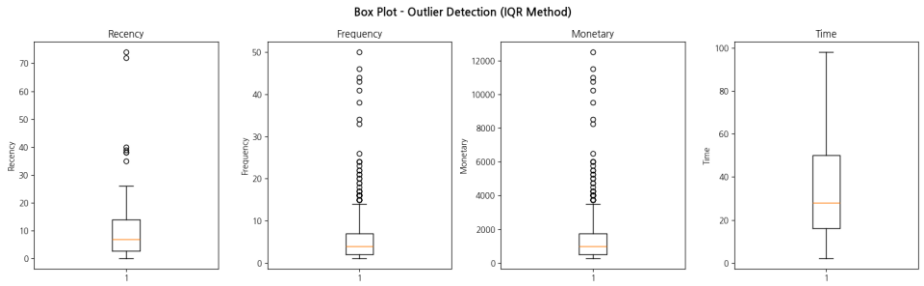

변수별 이상치 분포 Box Plot (실습파일_2.5)

3. 변수별 개별 특성 분석 (Univariate Analysis)

3.1 수치형 변수 분석

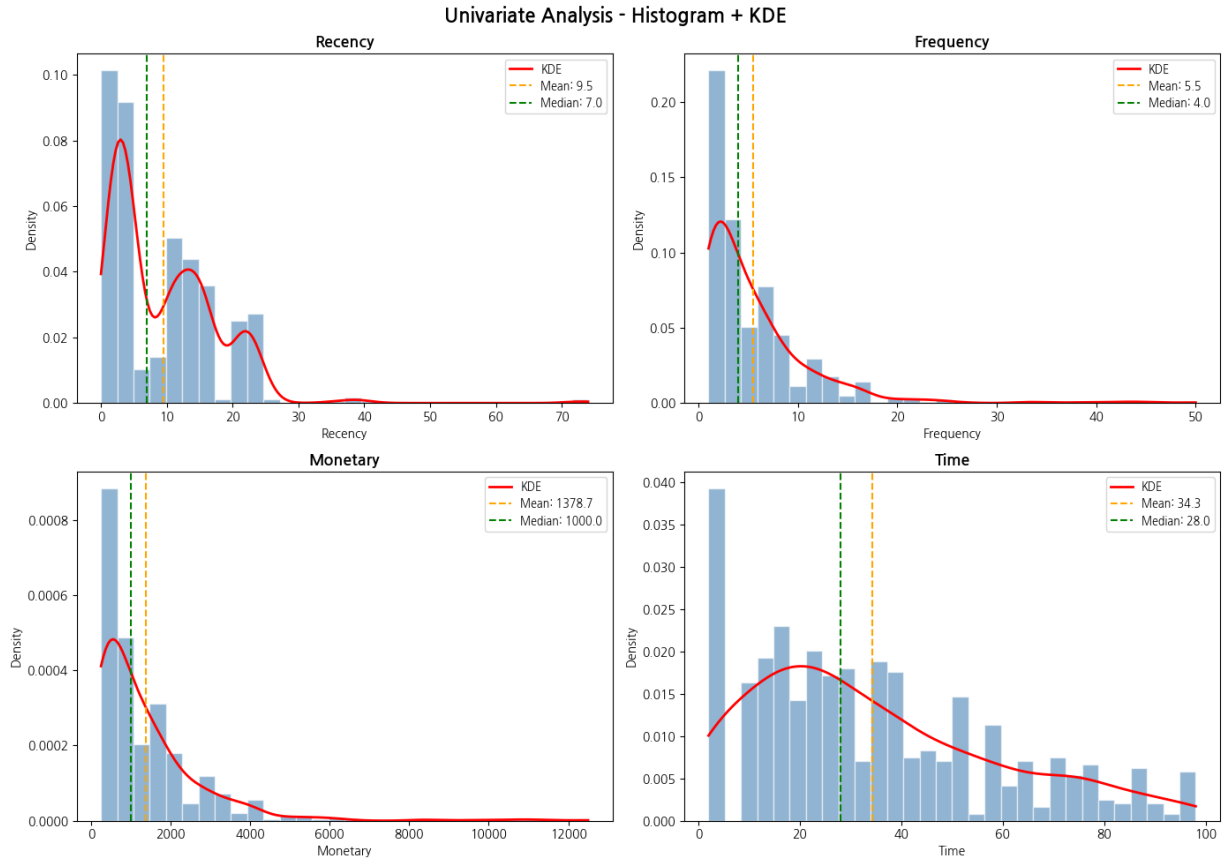

수치형 변수별 히스토그램 + KDE (실습파일_3.1)

① Recency (마지막 헌혈 후 경과 월)

왜도 (Skewness)	첨도 (Kurtosis)	분포 형태
1.880	9.391	강한 오른쪽(양의) 치우침 / 매우 뾰족

대부분의 헌혈자가 비교적 최근에 헌혈한 것으로 나타나며(중앙값 7개월), 소수의 헌혈자가 매우 오래전에 헌혈한 것이 긴 오른쪽 꼬리를 형성한다. 첨도(9.391)가 매우 높아 **극단적 이상치가 존재함을 시사**한다.

② Frequency (총 헌혈 횟수)

왜도 (Skewness)	첨도 (Kurtosis)	분포 형태
3.211	15.876	강한 오른쪽(양의) 치우침 / 매우 뾰족

대부분의 헌혈자가 1~4회의 저빈도 헌혈에 집중되어 있으며(최빈값 1회, 중앙값 4회), 50회까지 헌혈한 극단적 고빈도 헌혈자가 존재한다. 왜도(3.211)와 첨도(15.876)가 모두 매우 높아 **급속 구조의 분포**이다.

③ Monetary (총 헌혈량 c.c.)

왜도 (Skewness)	첨도 (Kurtosis)	분포 형태
3.211	15.876	강한 오른쪽(양의) 치우침 / 매우 뾰족

Monetary는 Frequency × 250으로 계산되므로 Frequency와 완전히 동일한 분포 형태를 보인다 (왜도 3.211, 첨도 15.876 동일). 헌혈 1회 = 250cc 고정이므로 사실상 Frequency와 동일 변수이다.

④ Time (첫 헌혈 이후 경과 월)

왜도 (Skewness)	첨도 (Kurtosis)	분포 형태
0.749	-0.246	약한 오른쪽 치우침 / 정규분포에 가까움

4개 변수 중 가장 정규분포에 가까운 형태이다. 첨도가 -0.246으로 0에 가까워 정규분포와 유사한 모양을 보인다. 헌혈자들의 첫 헌혈 시기가 **비교적 골고루 분포**되어 있음을 의미한다.

3.2 왜곡 변수 전처리

수치형 변수의 왜도가 높은 경우, 3가지 변환 방법을 적용하여 정규분포에 가깝게 변환하였다.

변수	원본 왜도	① 로그 변환	② 루트 변환	③ 박스-콕스 변환
Recency	1.880	-0.021	0.456	-0.005 (λ=0.016)
Frequency	3.211	0.453	1.258	0.018 (λ=-0.069)
Time	0.749	-0.812	0.017	-0.108 (λ=0.429)

Recency와 Frequency는 박스-콕스 변환이 가장 정규분포에 가까운 결과를 보였고, Time은 루트 변환이 가장 효과적이었다(왜도 절댓값 0.017).

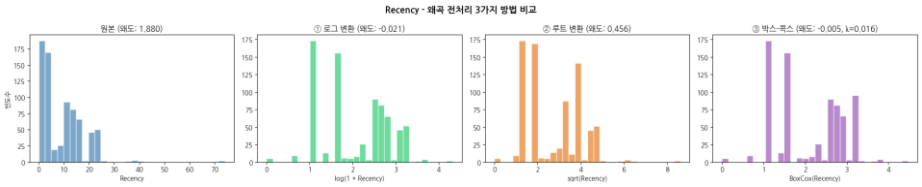

Recency 변환 전후 히스토그램 비교 (실습파일_3.2)

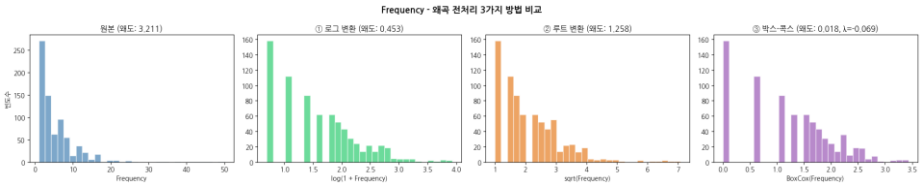

Frequency 변환 전후 히스토그램 비교 (실습파일_3.2)

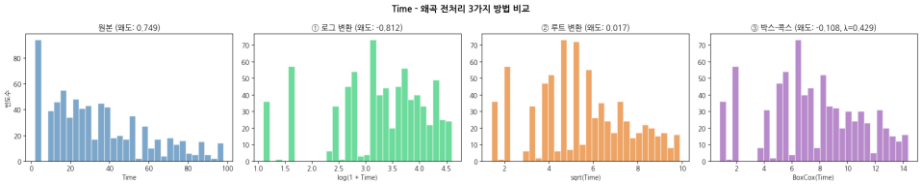

Time 변환 전후 히스토그램 비교 (실습파일_3.2)

3.3 범주형 변수 분석

클래스별 빈도수 및 비율 분석

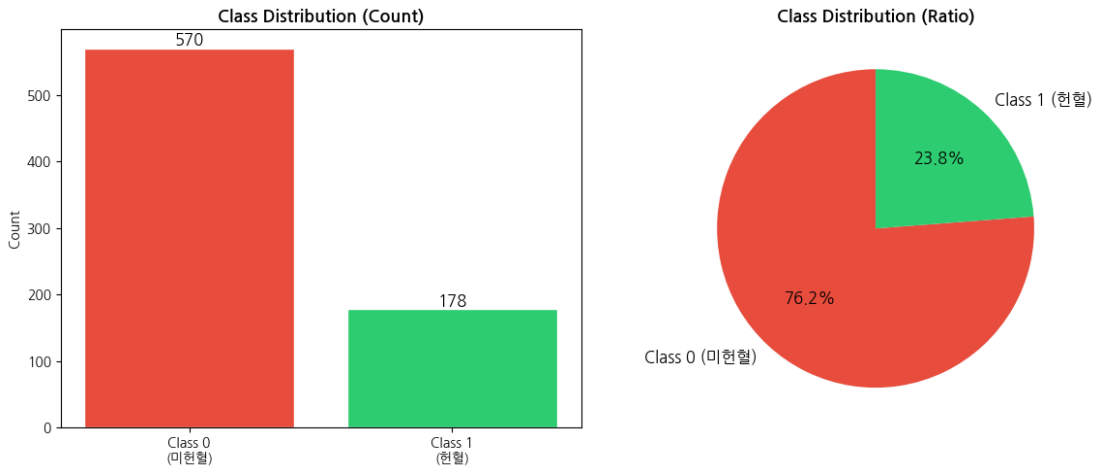

Class 별 막대그래프 및 파이 차트 (실습파일_3.3)

Class 값	의미	빈도수	비율(%)
0	미헌혈 (2007년 3월)	570	76.2%
1	헌혈 (2007년 3월)	178	23.8%

Class=0(미헌혈)이 76.2%, Class=1(헌혈)이 23.8%로 약 1:3의 클래스 불균형이 존재한다. 향후 모델링 시 SMOTE 오버샘플링 또는 class_weight 조정이 필요하다.

희소 클래스(Rare Labels) 존재 여부 확인

희소 클래스란 전체 데이터에서 비율이 매우 낮은 클래스(통상 5% 미만)를 의미한다.

확인 항목	결과	판단
Class=1 비율	23.8%	희소 클래스 해당 아님 (5% 초과)
최소 빈도 클래스	Class 1 (178명)	클래스 불균형 존재 (1:3 비율)

Class=1 비율이 23.8%로 희소 클래스 기준(5%)에는 해당하지 않으나, 클래스 불균형이 존재하므로 향후 모델링 시 SMOTE 오버샘플링 또는 class_weight 조정을 고려해야 한다.

3.4 파생 변수 생성 (Feature Engineering): 범주 재그룹화(Binning)

수치형 변수를 구간(범주)으로 나누는 Binning을 통해 새로운 파생 변수를 생성하였다.

① Recency Binning (마지막 헌혈 경과 월 → 구간화)

구간 기준: 단기(0~6개월), 중기(7~12개월), 장기(13개월 이상)

구간	범위	빈도수	비율(%)
단기	0~6개월	367	49.06%
중기	7~12개월	127	16.98%
장기	13개월 이상	254	33.96%

② Frequency Binning (헌혈 횟수 → 구간화)

구간 기준: 저빈도(1~2회), 중빈도(3~5회), 고빈도(6회 이상)

구간	범위	빈도수	비율(%)
저빈도	1~2회	270	36.10%
중빈도	3~5회	211	28.21%
고빈도	6회 이상	267	35.70%

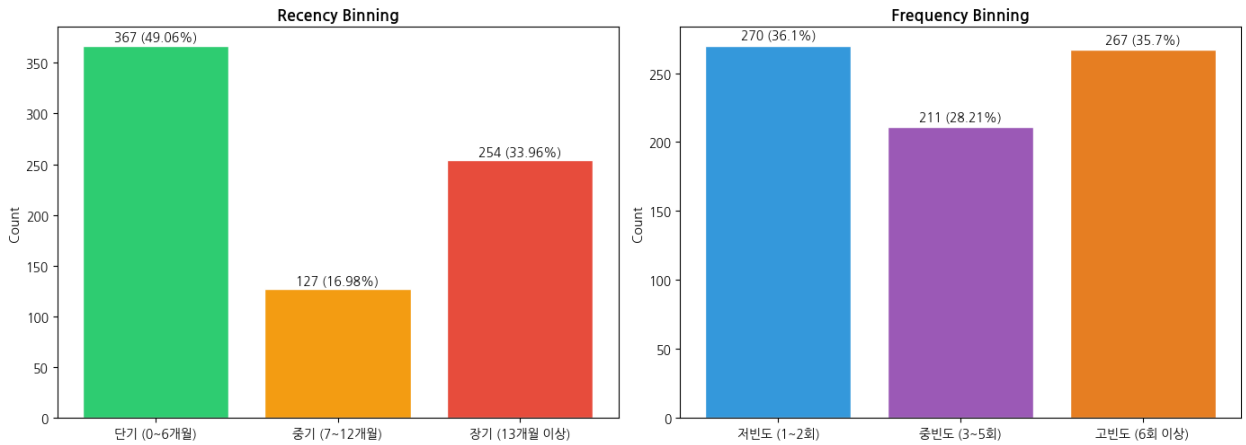

Recency / Frequency Binning 결과 (실습파일_3.4)

저빈도 헌혈자(36.1%)와 고빈도 헌혈자(35.7%)가 비슷한 비율로 양극화되어 있으며, 중빈도는 28.2%로 상대적으로 적다. 이는 헌혈자가 **'한두 번 하고 그만두는 그룹'**과 **'꾸준히 계속하는 그룹'**으로 **양분됨**을 의미한다.

4. 상관관계 및 관계 분석 (Multivariate Analysis)

4.1 수치형 변수 간 상관관계

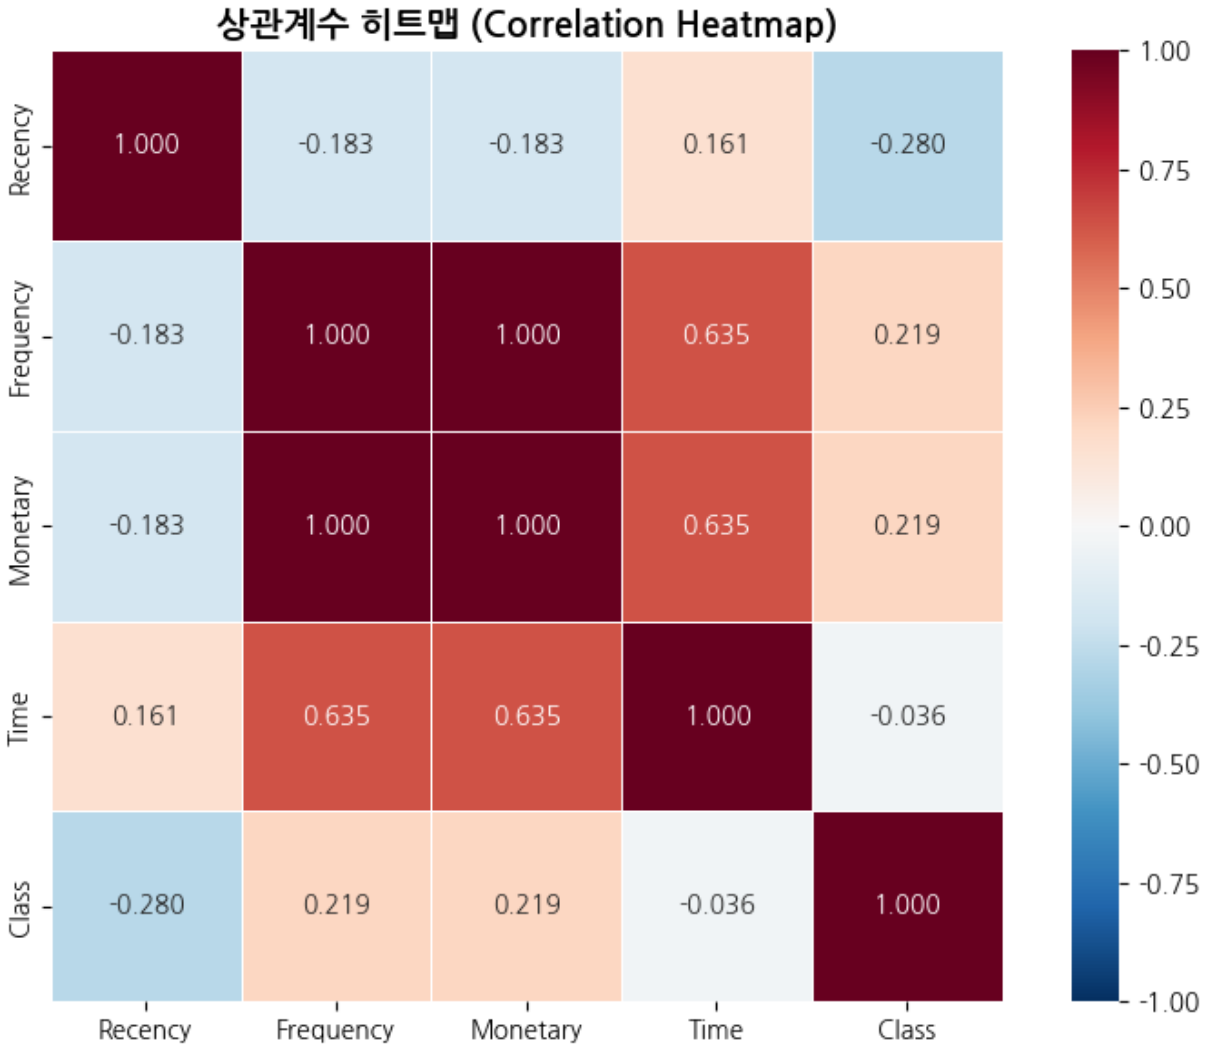

상관계수 히트맵(Heatmap) (실습파일_4.1)

변수 쌍	상관계수 (r)	관계 강도 해석
Frequency ↔ Monetary	1.000	완전 양의 상관 (동일 변수)
Recency ↔ Frequency	-0.183	거의 없는 음의 상관
Recency ↔ Class	-0.280	약한 음의 상관
Frequency ↔ Class	0.219	약한 양의 상관
Time ↔ Frequency	0.635	중간 양의 상관

다중공선성 확인: Frequency ↔ Monetary 상관계수가 r = 1.000으로 사실상 동일 변수이다(헌혈 1회 = 250cc 고정). 향후 모델링 시 둘 중 하나를 제거해야 한다.

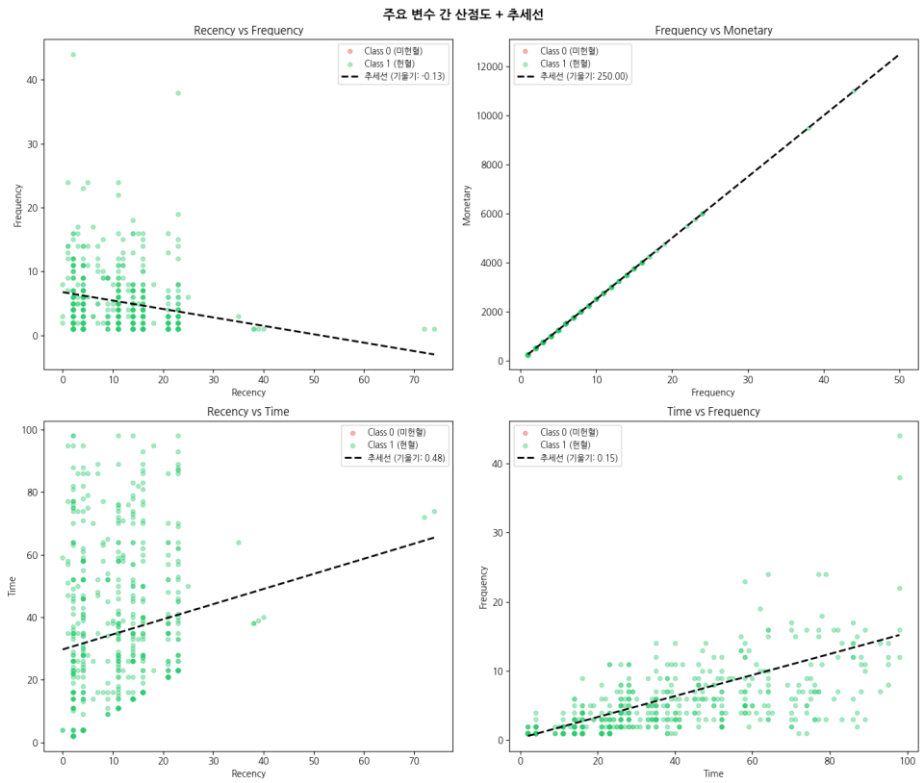

주요 변수 쌍 산점도(Scatter Plot) + 추세선 (실습파일_4.1)

산점도 분석 결과, **Frequency**와 **Monetary**는 완전한 선형 관계를 보이며, **Time**과 **Frequency** 사이에는 양의 추세가 확인된다. **Recency**와 **Frequency**는 약한 음의 관계로, <u>자주 헌혈하는 사람이 최근에도 헌혈한 경향이 있음을 시사</u>한다.

4.2 타겟 변수(Class) 기반 심층 분석

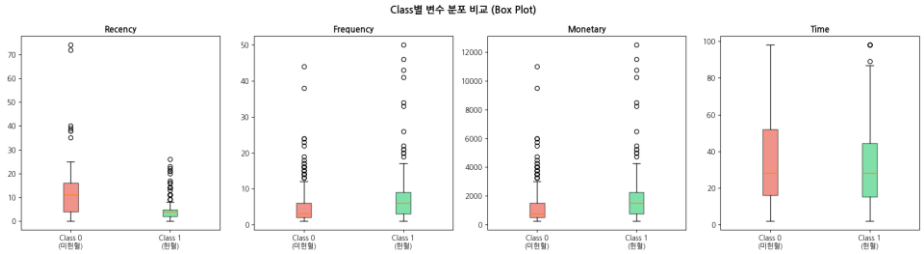

[그림 4-3] Class 별 Box Plot

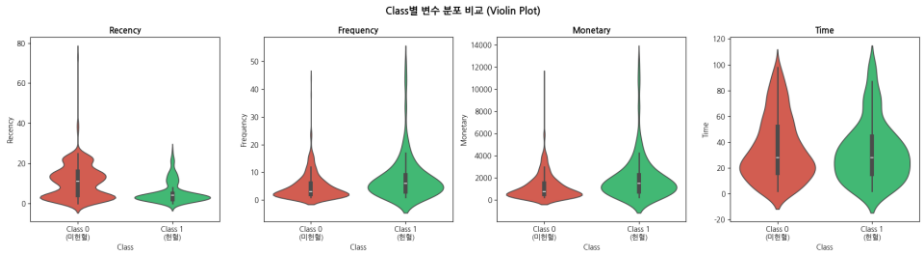

Class 별 Violin Plot (실습파일_4.2)

변수	Class=0 평균	Class=1 평균	차이 해석
Recency	10.77	5.46	재헌혈자는 마지막 헌혈이 훨씬 최근 (-5.32)
Frequency	4.80	7.80	재헌혈자는 헌혈 횟수가 더 많음 (+3.00)
Monetary	1200.44	1949.44	재헌혈자는 총 헌혈량이 더 많음 (+749)
Time	34.77	32.72	큰 차이 없음 (-2.05)

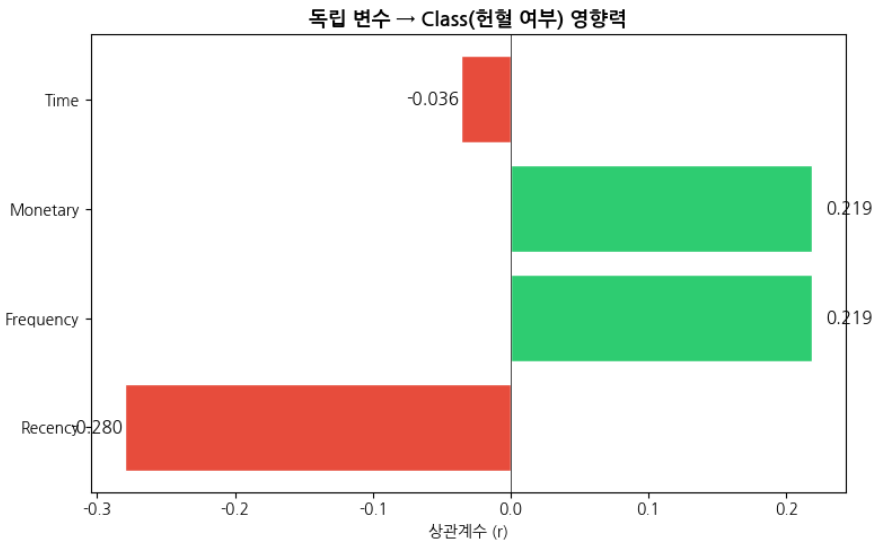

독립 변수 → Class 영향력 비교 (실습파일_4.2)

Recency(r = -0.280)가 Class에 가장 강한 음의 상관을 보여 재헌혈 예측의 핵심 변수임을 확인하였다. Frequency(r = 0.219)와 Monetary(r = 0.219)는 양의 상관을, Time(r = -0.036)은 **거의 무관한** 것으로 나타났다.

4.3 세그먼트별 비교 분석

헌혈 횟수 기준으로 저빈도 헌혈자(1~2회, 270명) vs 고빈도 헌혈자(6회 이상, 267명)의 행동 패턴 차이를 비교하였다.

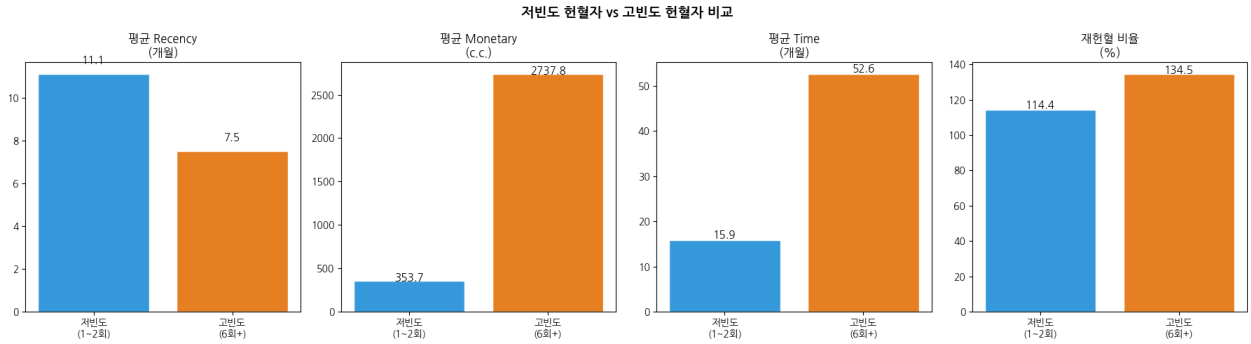

저빈도 vs 고빈도 헌혈자 비교 (실습파일_4.3)

지표	저빈도(1~2회)	고빈도(6회+)	해석
평균 Recency	11.10개월	7.48개월	고빈도가 더 최근에 헌혈
평균 Monetary	353.70cc	2737.83cc	고빈도가 압도적으로 많음
평균 Time	15.88개월	52.60개월	고빈도는 오래전부터 헌혈
재헌혈률(Class=1)	14.4%	34.5%	고빈도가 재헌혈률도 높음

고빈도 헌혈자는 저빈도 헌혈자에 비해 재헌혈률이 2.4배 높으며**(34.5% vs 14.4%)**, 평균 Recency도 짧아 **핵심 공급자 역할**을 하고 있음을 확인하였다.

5. 핵심 인사이트 및 가설 검정 (Key Insights)

5.1 주요 패턴 발견

패턴 1: Recency(최근성)가 재헌혈 여부의 가장 강력한 예측 변수

Recency ↔ Class 상관계수가 -0.280으로 전체 변수 중 가장 강한 상관을 보였다. Class=0(미헌혈) 평균 Recency는 10.77개월, Class=1(헌혈)은 5.46개월로, 재헌혈한 사람은 마지막 헌혈이 훨씬 최근이었다.

패턴 2: Frequency와 Monetary의 완전 다중공선성

Frequency ↔ Monetary 상관계수가 1.000으로, 헌혈 1회 = 250cc 고정이므로 Monetary = Frequency × 250이다. 사실상 동일 변수이므로 모델링 시 하나를 제거해야 한다.

패턴 3: 헌혈자 양극화 현상

저빈도(1~2회) 270명(36.1%), 고빈도(6회+) 267명(35.7%)으로 비슷한 비율의 양극화가 발생하였다. 고빈도 헌혈자의 재헌혈률(34.5%)이 저빈도(14.4%)보다 현저히 높아 핵심 공급자 역할을 한다.

5.2 가설 검증 결과

가설	검증 결과	근거 (그래프·수치 기반)
가설 1: Time 분포의 공급 주기 집중	기각	Time이 3의 배수인 데이터: 125개/748개(16.7%). 집중 현상 불분명
가설 2: Recency 기반 Churn 이탈 패턴	채택	0~3개월: 37.4%, 4~6개월: 37.1%, 7~12개월: 15.0%, 13개월+: 8.7%
가설 3: Frequency↑ → Recency↑ JIT 병목	기각	r = -0.183 (음의 상관). 고빈도 헌혈자가 오히려 최근에 헌혈
가설 4: Monetary↑ → Class=1 확률↓ 역설	기각	r = 0.219 (양의 상관). 헌혈량 많을수록 재헌혈 확률 높음

가설 1 : Time이 3의 배수인 비율이 16.7%에 불과하여 3개월 주기 집중 현상이 불분명하다.

(기각)

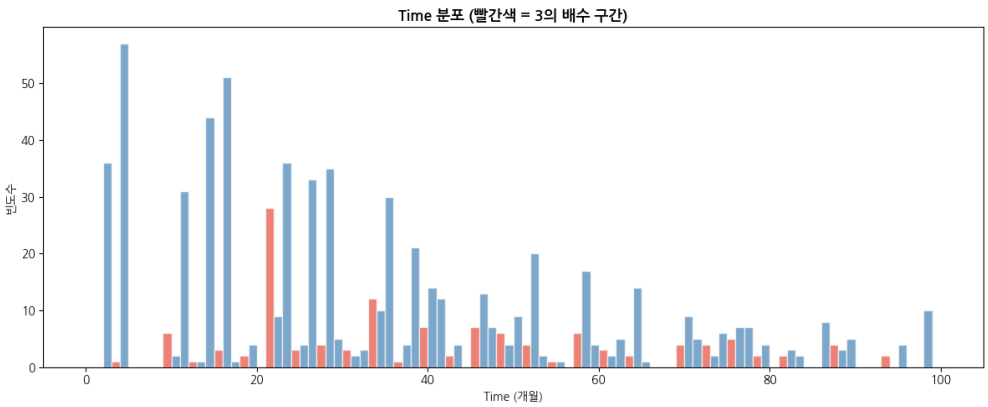

가설 1 검증 — Time 분포 (3의 배수 강조) (실습파일_5.2)

가설 2: Recency가 길어질수록 재헌혈 비율이 뚜렷하게 감소하였다. 0~3개월(37.4%)에서 13개월+(8.7%)로 급격히 하락하여 로그함수적 이탈 패턴이 확인되었다. **(채택)**

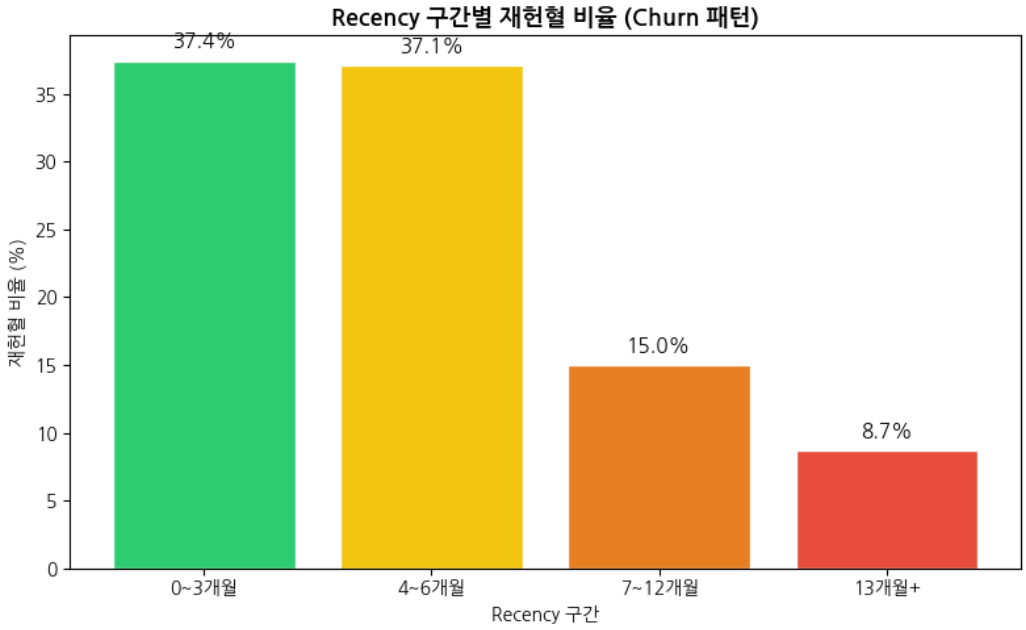

가설 2 검증 — Recency 구간별 재헌혈 비율 (실습파일_5.2)

가설 3: Frequency와 Recency 간 상관계수가 -0.183으로, 고빈도 헌혈자가 오히려 최근에 헌혈하는 패턴을 보였다. JIT 병목 현상은 발견되지 않았다. **(기각)**

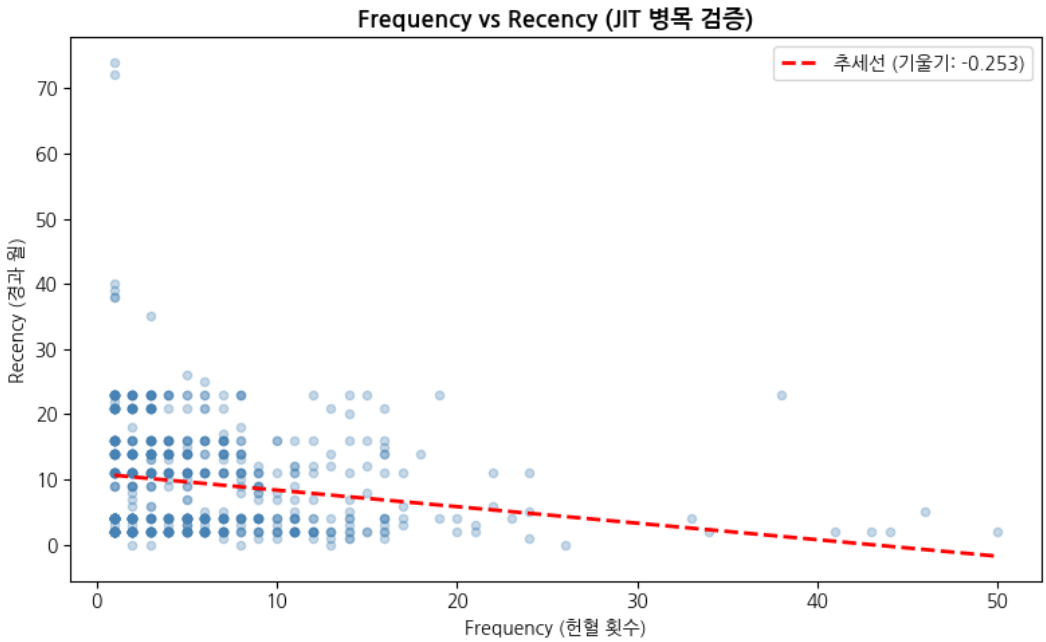

가설 3 검증 — Frequency vs Recency 산점도 (실습파일_5.2)

가설 4: Monetary ↔ Class 상관계수가 0.219(양의 상관)로, 헌혈량이 많을수록 재헌혈 확률이 높았다. 예상과 반대로 역설이 아닌 충성 헌혈자 패턴으로 해석된다. (~500cc: 14.4%, 501~1000cc: 18.1%, 1001~2000cc: 33.0%, 2001cc+: 35.5%) (기각)

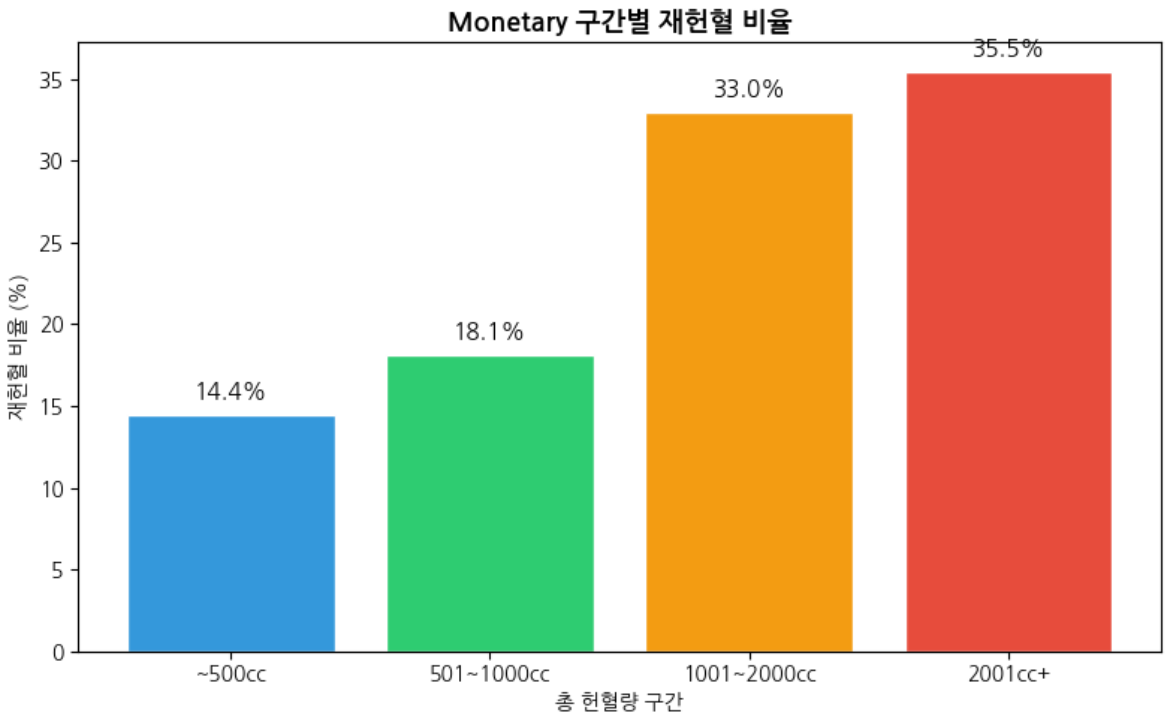

가설 4 검증 — Monetary 구간별 재헌혈 비율 (실습파일_5.2)

5.3 예상치 못한 발견 (Unexpected Findings)

본 분석은 초기 설계 단계에서 보다 복합적인 가설을 수립하였으나, 데이터셋의 구조적 한계로 인해 검증 가능한 형태로 재설계하는 과정을 거쳤다. 이 과정에서 발견된 예상치 못한 **사례**는 다음과 같다.

발견 1: 가설 4 기각에서 드러난 충성 헌혈자(Loyal Donor) 패턴

가설 4에서 총 헌혈량이 높을수록 재헌혈 확률이 낮아질 것으로 예상했으나, 실제로는 Monetary ↔ Class: r = 0.219(양의 상관)로 반대 결과가 나왔다. 충성 헌혈자(10회+) 117명의 재헌혈률은 37.6%로, 일반 헌혈자(10회-) 631명의 21.2%보다 현저히 높았다. **고헌혈자는 이탈 위험군이 아닌 핵심 자산이며, VIP 관리 프로그램이 필요하다.**

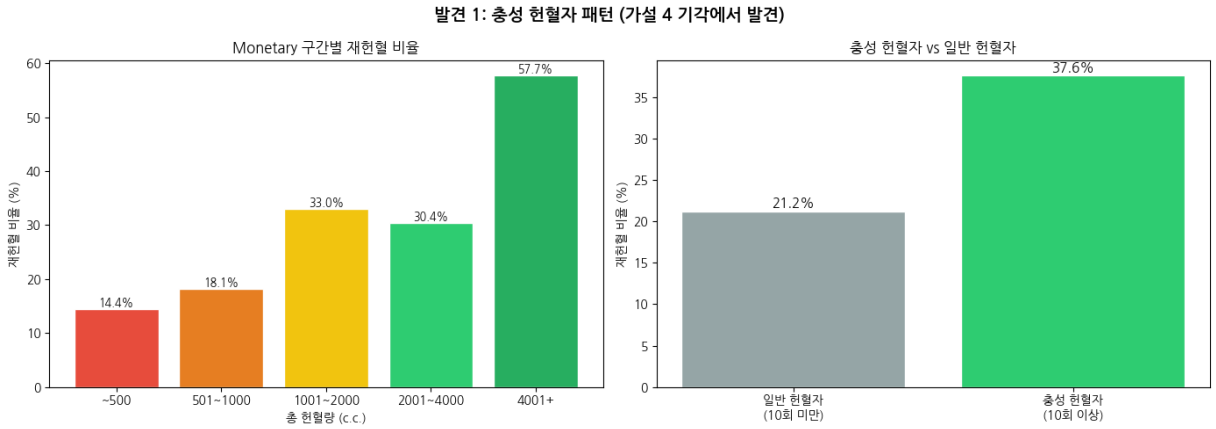

발견 1 — 충성 헌혈자 vs 일반 헌혈자 비교 (실습파일_5.3)

발견 2: 헌혈 밀도(Frequency / Time) — RFMTC에 없는 새로운 예측 지표

3장 Frequency/Time 분석 중 두 변수를 조합한 헌혈 밀도(Frequency ÷ Time)가 기존 RFMTC 변수보다 높은 예측력을 보였다. Class 상관계수: Recency(r = -0.280), 헌혈 밀도(r = 0.260), Frequency(r = 0.219), Time(r = -0.036). RFMTC 모델에 헌혈 밀도를 추가한 확장 모델(RFMTC+D) 구축을 제안한다.

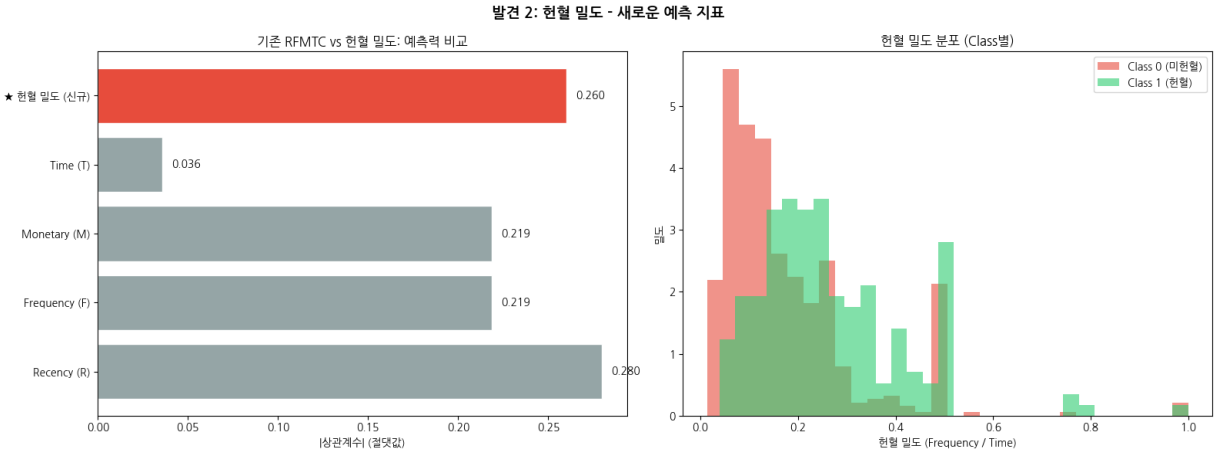

발견 2 — 헌혈 밀도 vs 기존 변수 상관계수 비교 (실습파일_5.3)

발견 3: 장기 헌혈자의 역설적 이탈 — 경력 ≠ 충성도

4.2에서 Time ↔ Class가 -0.036으로 무의미해 보였으나, 구간별로 쪼개보니 장기 헌혈자(61개월+)는 헌혈 횟수는 평균 12.0회로 높지만 재헌혈률은 19.7%로 오히려 낮아지는 역설적 패턴이 숨어있었다. **장기 헌혈자를 안정적 공급자로 간주하지 말고, Recency + 헌혈 밀도 기반 이탈 조기 경보 시스템 구축이 필요하다**.

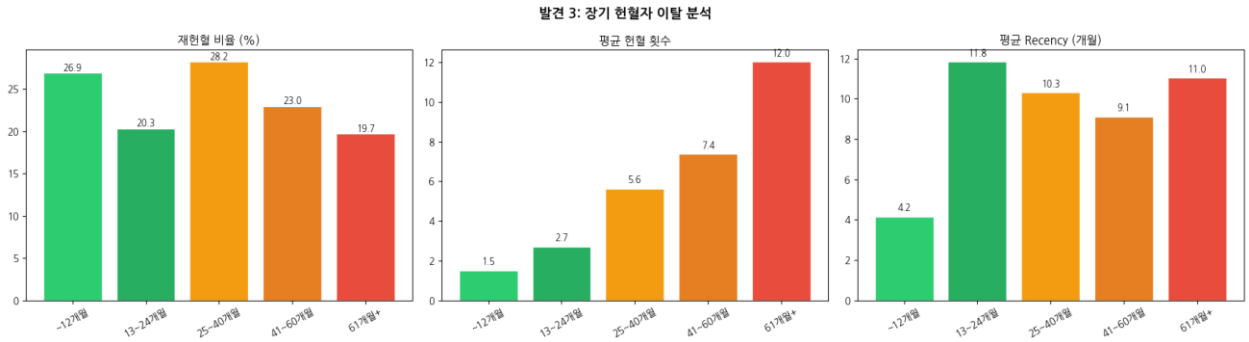

발견 3 — Time 구간별 재헌혈률 및 헌혈 횟수 (실습파일_5.3)

발견 4: JIT 신체 회복 제약 가설의 수정

고빈도 헌혈자의 신체 회복 기간 데이터가 존재하지 않아, 원래 가설을 Frequency와 Recency 간의 비선형 관계 검증으로 재설계하였다.

6. 결론 및 향후 방향 (Conclusion & Recommendation)

6.1 분석 요약

본 보고서는 대만 신주시 헌혈 서비스 센터의 748명 헌혈자 데이터를 RFMTC(Recency, Frequency, Monetary, Time, Class) 모델 기반으로 탐색적 데이터 분석(EDA)을 수행하였다. 혈액 공급망의 구조적 문제를 데이터 기반으로 진단하고, 헌혈자 이탈 방지를 위한 인사이트를 도출하는 것을 목적으로 하였다.

2장에서 4가지 방법으로 데이터를 수집하고 748행 × 5열의 데이터셋을 확인하였다. 결측치는 0개로 별도 처리가 불필요하였으며, 이상치는 IQR 방법으로 탐지한 결과 Frequency·Monetary에서 발견되었으나 실제 헌혈 패턴을 반영하는 유의미한 값으로 판단하여 유지하였다.

3장 단변량 분석에서 4개 수치형 변수 모두 오른쪽으로 치우친 양의 왜도 분포를 보였으며, 타겟 변수(Class)는 미헌혈 76.2% vs 헌혈 23.8%로 클래스 불균형이 존재하였다. Binning 분석 결과, 저빈도(36.1%)와 고빈도(35.7%)가 비슷한 비율로 양극화 패턴을 보였다.

4장 다변량 분석에서 Recency(r=-0.280)가 Class에 가장 강한 음의 상관을 보여 재헌혈 예측의 핵심 변수임을 확인하였다. Frequency와 Monetary는 r=1.000으로 완전 다중공선성이 존재하였다.

5장에서 4개 가설 중 가설 2(Recency Churn 패턴)가 가장 뚜렷하게 채택되었으며, 가설 4 기각에서 충성 헌혈자 패턴, 헌혈 밀도(Frequency÷Time) 새로운 예측 지표, 장기 헌혈자 이탈 역설 등 예상치 못한 발견으로 이어졌다.

혈액 공급망의 안정성은 소수의 고빈도 충성 헌혈자에 크게 의존하고 있으며, Recency 기반 이탈 조기 감지와 헌혈 밀도를 활용한 정밀 관리가 혈액원 운영 효율화의 핵심 전략임을 본 분석을 통해 확인하였다.

6.2 비즈니스 제언 (Action Plan)

분석 결과를 바탕으로 혈액원 운영 효율화를 위한 실행 방안을 다음과 같이 제안한다.

제언 1: Recency 기반 이탈 방지 리마인더 시스템 구축

분석 결과, Recency가 6개월을 초과하면 재헌혈 비율이 급격히 하락하였다. 따라서 마지막 헌혈 후 3개월 시점에 1차 리마인더(SMS/앱 알림), 5개월 시점에 2차 리마인더를 발송하여 이탈 전 재방문을 유도해야 한다. 이는 헌혈 버스의 3개월 주기 방문 일정과도 연동 가능하다.

제언 2: 충성 헌혈자(VIP) 관리 프로그램 도입

가설 4 검증에서 고헌혈자가 이탈하지 않고 오히려 재헌혈률이 높은 충성 헌혈자 패턴이 발견되었다. 이 핵심 공급자 그룹(Frequency 10회+)을 VIP로 지정하고, 감사 메시지·건강검진 쿠폰·우선 예약 등의 혜택을 제공하여 이탈을 사전에 방지해야 한다.

제언 3: RFMTC+D 확장 모델을 활용한 이탈 조기경보 시스템

5.3에서 발견한 헌혈 밀도(Frequency÷Time)는 기존 RFMTC 모델에 없는 새로운 예측 지표로, 횟수보다 꾸준함이 재헌혈 예측에 더 효과적이었다. 또한 장기 헌혈자(Time↑)도 이탈할 수 있다는 발견을 종합하면, Recency + 헌혈 밀도를 결합한 이탈 점수(Churn Score)를 산출하고, 위험 임계점 도달 시 자동으로 관리 대상에 편입하는 조기경보 시스템을 구축할 것을 제안한다.

6.3 한계점 및 추후 과제

본 분석의 구조적 한계와 향후 연구 방향은 다음과 같다.

① 데이터 규모 및 대표성 한계

748개 샘플은 대만 신주시 특정 대학 방문 기록에 한정되어 있어 전체 헌혈 인구로의 일반화에 한계가 있다. 또한 나이·성별·직업 등 인구통계학적 변수가 포함되어 있지 않아 헌혈자 세그먼트 분석에 제약이 있다.

② 외부 데이터 부재로 인한 가설 검증 한계

채찍 효과 검증을 위한 병원 혈액 수요 데이터, 기상 경제학적 리스크 검증을 위한 기온 데이터, JIT 신체 회복 제약 검증을 위한 헌혈자 건강 데이터가 부재하여 초기 설계한 복합 가설의 직접 검증이 불가능하였다.

③ EDA의 분석적 한계

본 보고서는 탐색적 데이터 분석(EDA) 단계에 해당하므로 변수 간 인과관계(Causality)가 아닌 상관관계(Correlation)만을 확인할 수 있다. 향후 로지스틱 회귀, 랜덤 포레스트 등 머신러닝 모델을 도입하여 재헌혈 예측 모델을 구축하는 것을 추후 과제로 제안한다.

④ Monetary 변수의 정보 중복 문제

Frequency ↔ Monetary 상관계수가 r = 1.000으로, 헌혈 1회 = 250cc 고정이므로 5개 변수 중 실질적으로 독립적인 변수는 4개뿐이다. 이는 RFMTC 모델의 설계 자체에 정보 중복이 내재되어 있음을 의미한다.

⑤ 클래스 불균형으로 인한 분석 편향 가능성

Class=1(헌혈) 비율이 23.8%(약 1:3 불균형)로, EDA 단계에서는 시각화와 비율 비교로 대응하였으나, 향후 예측 모델 구축 시 SMOTE 오버샘플링, class_weight 조정, 또는 F1-score 기반 평가 등 불균형 대응 전략이 반드시 필요하다.

⑥ 시계열 정보 부재로 인한 추세 분석 불가

본 데이터셋은 특정 시점(2007년 3월)의 스냅샷 데이터로, 헌혈자의 행동 변화 추이나 계절적 패턴을 분석할 수 없었다. 향후 다년간 헌혈 기록 시계열 데이터 확보 시 추세 분석이 가능하다.

추후 과제 요약

1. Monetary 제거 후 RFMTC → RFTC 모델로 재설계
2. 헌혈 밀도(F/T) 추가한 확장 모델(RFMTC+D) 구축 및 검증
3. 클래스 불균형 대응 전략 적용한 머신러닝 예측 모델 개발
4. 다년간 시계열 데이터 확보하여 이탈 추세·계절성 분석
5. 인구통계학적 변수(나이, 성별) 결합한 세그먼트 심화 분석

*※ 코랩 코드 전체는 **GitHub** (링크: **EDA_혈액헌열_코랩코드**) 에 업로드하였습니다.*

※ 본 보고서는 데이터관리론 과제로 작성되었습니다.